Анализ и улучшение алгоритма расположения инвариантов цикла в компиляторной инфраструктуре LLVM с использованием статического и динамического профилирования

бакалаврская работа

Найданов Евгений Максимович

2023

Варианты расположения инварианта цикла

- **В теле цикла**
  Исходное расположение.
- **В предзаголовке цикла**
  Оптимально, если число итераций больше единицы.
- **В некоторых блоках выхода цикла**
  Доступно только если нет использований в цикле.

Пример: SPEC CPU® 2017. perlbench_r. S_regmatch

Структура функции:

- Основной цикл является горячим.
- Большое число случаев внутри конструкции switch.
- Некоторые из них осуществляют безусловный переход в начало тела цикла.

На данном примере при компиляции с использованием Clang, среднее число инструкций на итерацию цикла больше, чем у компилятора GCC.

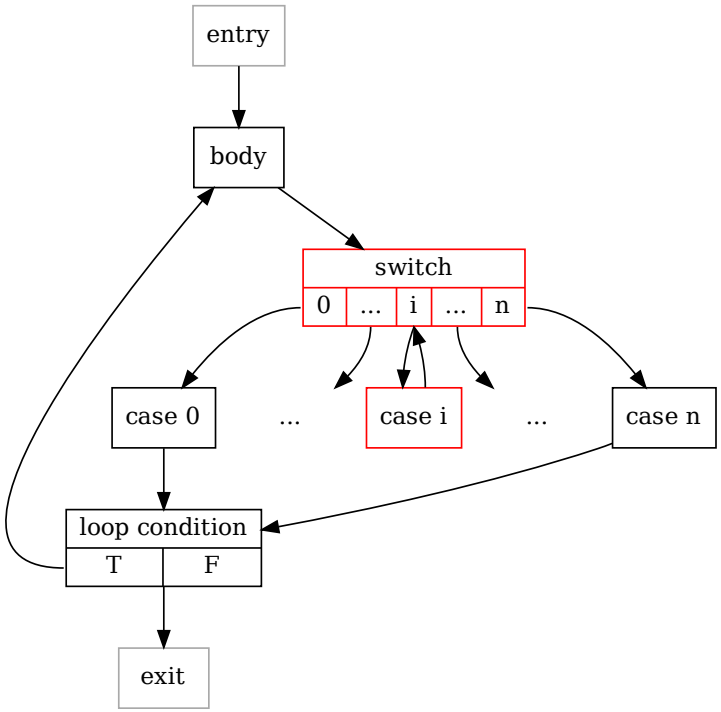

Формальная постановка задачи

- $M \subset \{\, d : p \; dom \; d \,\}$
- $\forall\, u \in U(i)\, \exists\, m \in M : m \; dom \; u$, где $U(i)$ - множество блоков, содержащих использование инварианта i.
- $\sum_{m \in M} f(m) \to min$, где $f(m)$ - оценка частоты вероятности исполнения блока m.

Подход к размещению инвариантов цикла в компиляторной инфраструктуре LLVM

- Вынос инвариантов из цикла
- Пропагация инвариантов в цикл
  - Анализ частот исполнения блоков
  - Анализ вероятности переходов

Вынос инвариантов из цикла

- Удаляется, если нет использований.
- Выносится в блоки выхода, если все использования вне цикла.
- Иначе выносится в предзаголовок.

Построение анализа частот исполнения блоков

- Обход циклов – сначала все вложеные циклы, затем внешний.
- Распределение веса в циклах

$$w_j = \sum_{E(V_i, V_j)} w_i p_{ij}$$

- Рассчет числа итераций циклов

$$s = \frac{1}{w_0 - w_b}$$

- Распределение веса в функции
- Рассчет частот исполнения блоков

Построение анализа вероятности переходов

- Метаданные
- Эвристика основанная на весах блоков
- Эвристики основаные на свойствах сравнений

Эвристика основанная на весах блоков

- Присвоение малых весов ребрам, входящим в редкоисполняемые блоки.
- Для ребер, с условием, которое перестает выполняться после некоторой итерации – вдвое меньший вес.
- Веса дуг, выходящих из цикла, делятся на оценку числа итераций цикла.

Эвристики основанные на свойствах сравнений

Эвристика	**Условие**	**Вероятность истинности условия**
Сравнение указателей	`p1 == p2`	0.375
	`p1 != p2`	0.625
Сравнение с константой	`i == 0`	0.375
	`i <0`	
	`i == -1`	
	`i <= 0`	
	`i != 0`	0.625
	`i >0`	
	`i != -1`	
	`i >= 0`	
Сравнение чисел с плавающей точкой	`f1 == f2`	0.375
	`f1 != f2`	0.625
	`!isnan(f)`	$1 - 2^{-20}$
	`isnan(f)`	2^{-20}

Получение динамического профиля исполнения программы

- Инструментация кода.
- Запуск программы для сбора профиля.
- Использование профиля при компиляции программы.

Сравнение с подходом в компиляторной инфраструктуре GCC

- Вынос инвариантов цикла не является приведением к канонической форме
  - Каждый инвариант обрабатывается строго один раз.
  - Больше инструкций в теле цикла.
- Статический анализ частот исполнения блоков точнее:
  - Использование большего колличества эвристик.
  - Использование алгоритма объединения эвристик.

Упроценый пример `S_regmatch_draft`

- Схожая структура
- 4 цикла
- `string[i]` – инвариант для внутренних циклов, но не для внешнего.

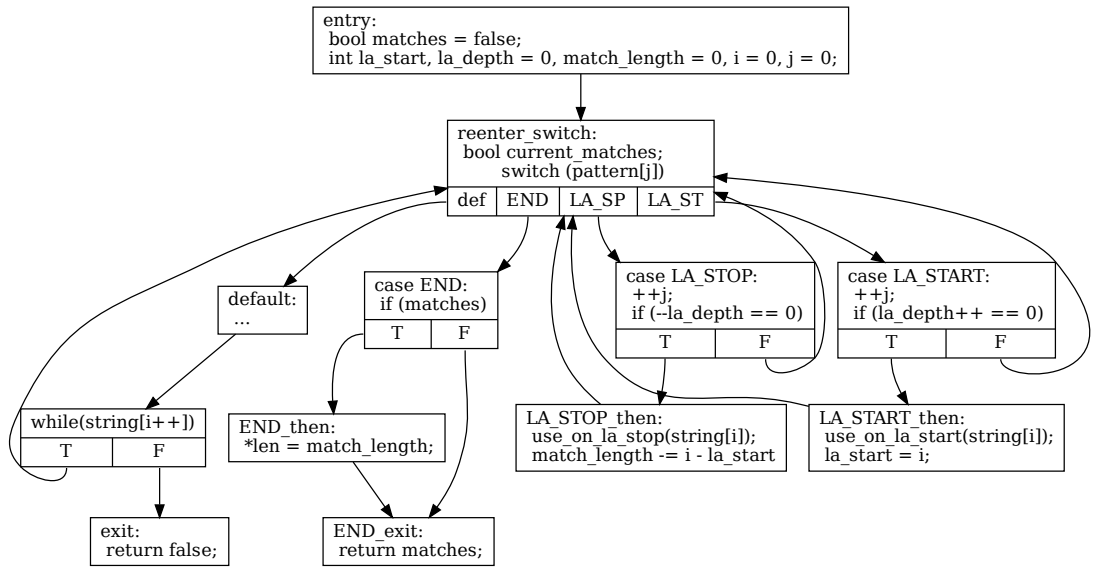

`S_regmatch_draft`. Построение упрощенной формы циклов

- Предзаголовок цикла `do.body`.
- Заголовок `loop2.header`.

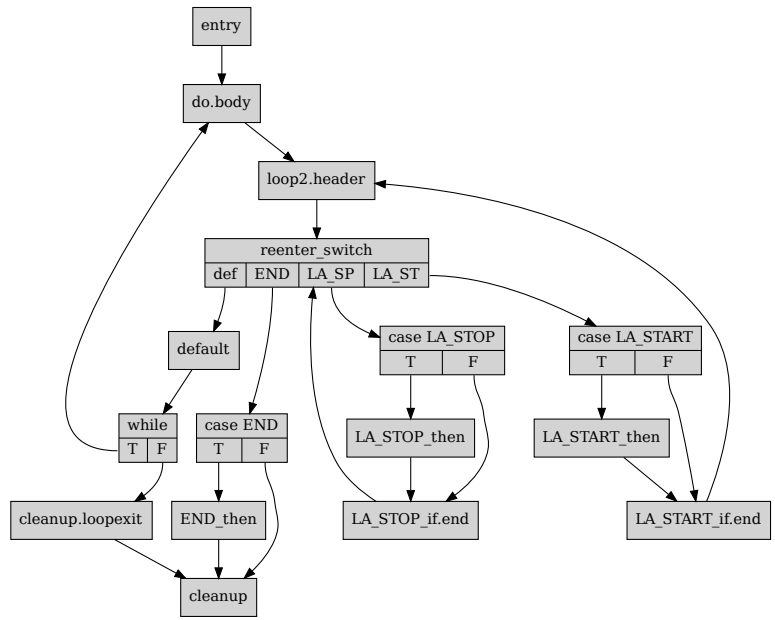

S_regmatch_draft. Упрощенная форма циклов

- Заголовки `loop1-3.header` и `reenter_switch`.
- Предзаголовки `do.body` и `loop1-3.header`.

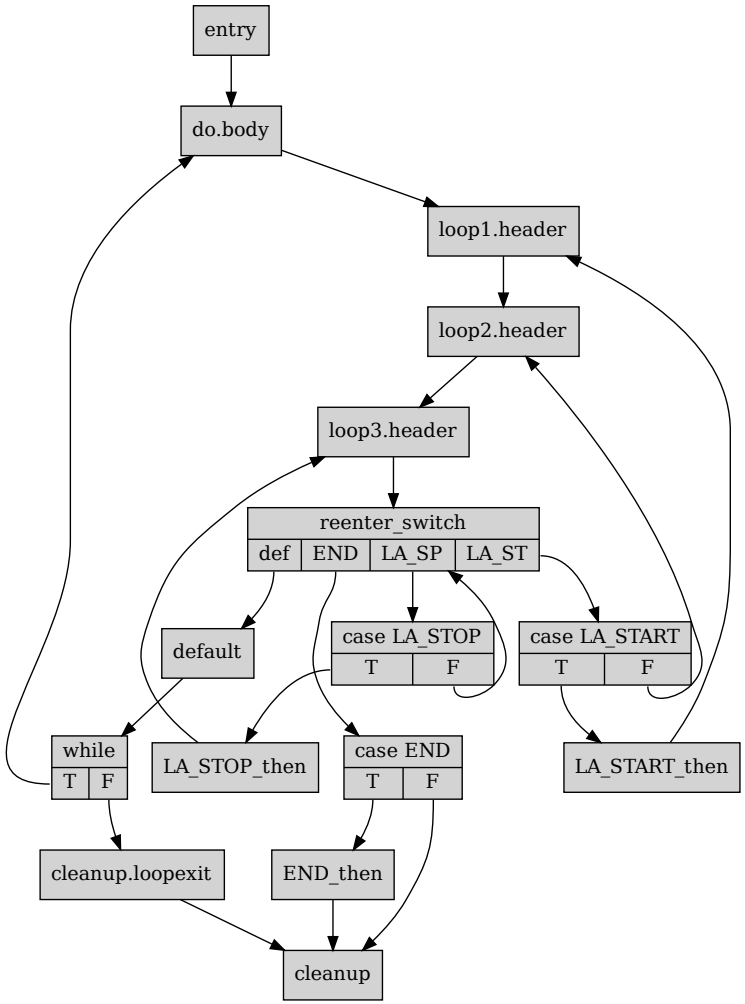

Расположение инварианта `string[i]`

- Вынос инвариантов из цикла – расположен в `do.body`.
- Если не спропагирован, число исполнений – длинна строки `string`.
- Если спропагирован в `LA_START_then` и `LA_STOP_then` – сумма числа токенов `LA_START` и `LA_STOP` в шаблоне `pattern`.

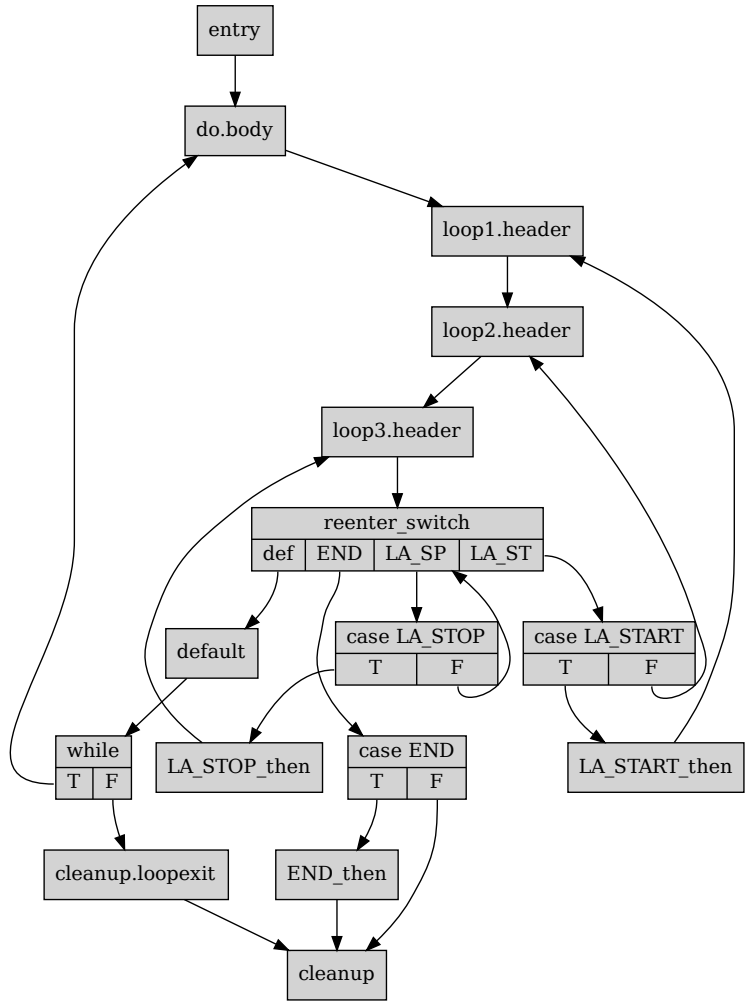

Предлагаемые улучшения. Пропагация инвариантов с использованием в φ узлах

- Многие инварианты цикла могут быть использован в некотором φ узле.
- Невозможно спропагировать в базовые блок в котором находится этот φ узел.
- Решение: рассматривать базовый блок из которого поток управления входит в узел с данным значением.

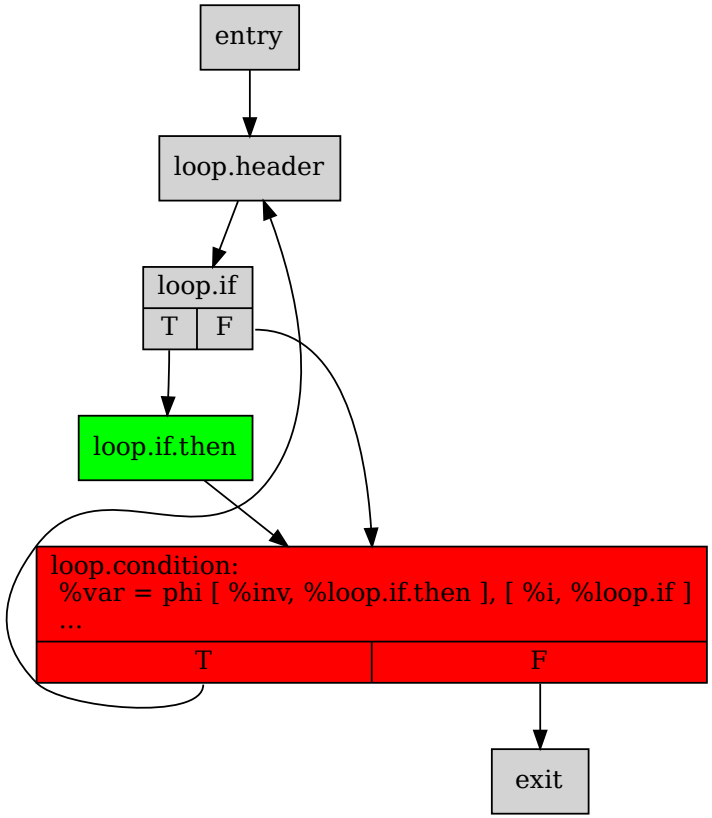

Предлагаемые улучшения. Пропагация инвариантов во все доминируемые базовые блоки

- Использование инварианта как внутри, так и вне цикла.
- Рассматривать блоки цикла и блоками выхода недостаточно.
- Следует рассматривать все базовые блоки, доминируемые предзаголовком.

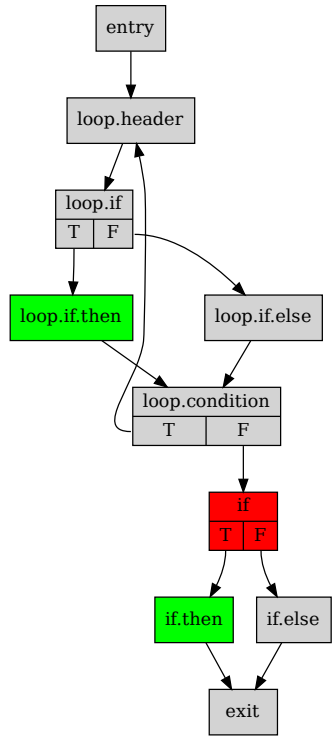

Анализ полученного алгоритма

- В работе доказана оптимальность получаемых расположений с точки зрения минимизации суммарной частоты исполнения.
- Ассимптотика алгоритма:
  - В среднем: $O(N)$
  - В худшем случае: $O(N^2)$

Производительность алгоритма. Методика измерений

- СнК Alibaba T-Head XuanTie C910 ICE, Линукс. 2 ядра. 1.2 ГГц. RISC-V 64 GC.
- Время исполнения программы в тактах и число исполненных инструкций
- Сбор значений соттветствующих счетчиков процессора, при помощи программы perf.
- Использовалось динамического профилирование.

Производительность алгоритма. SPEC CPU® 2017

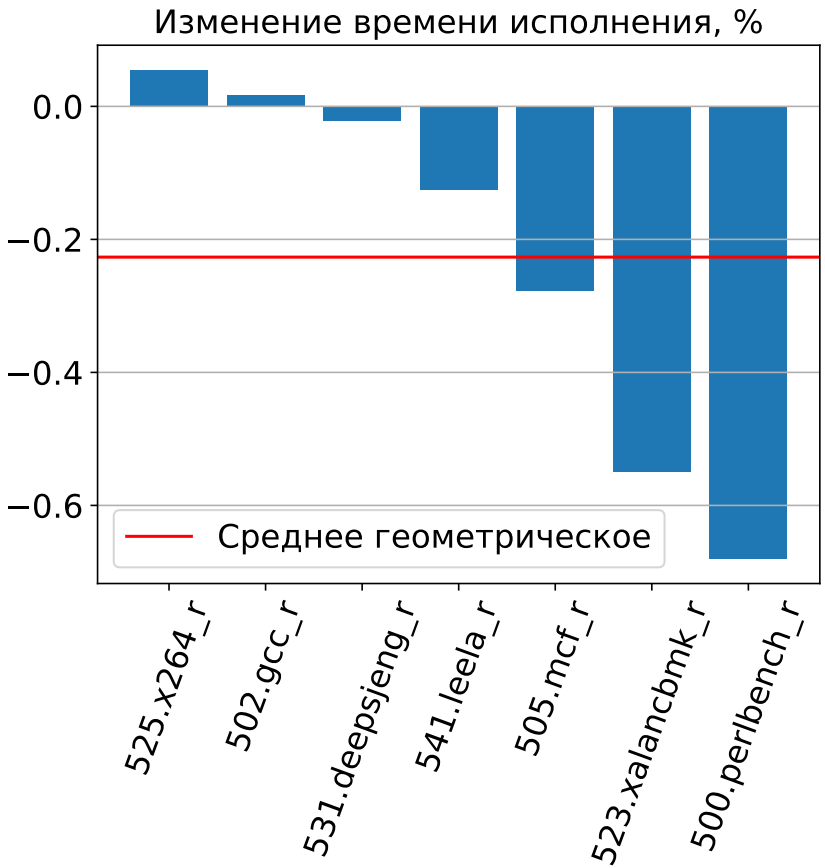

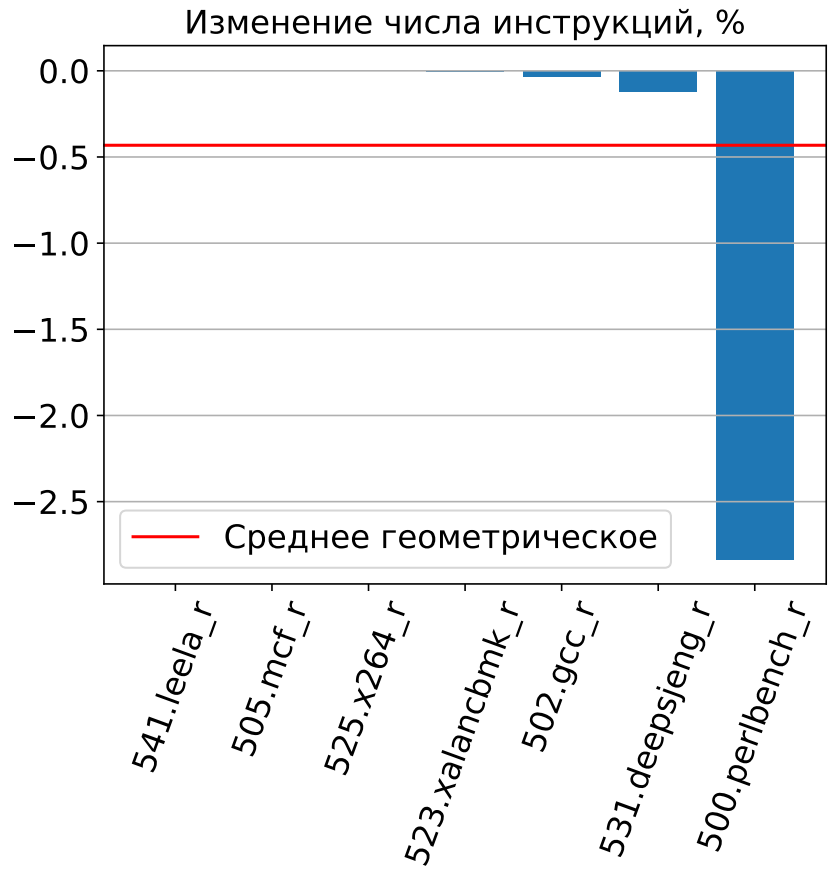

Производительность алгоритма. Коллекция тестов LLVM

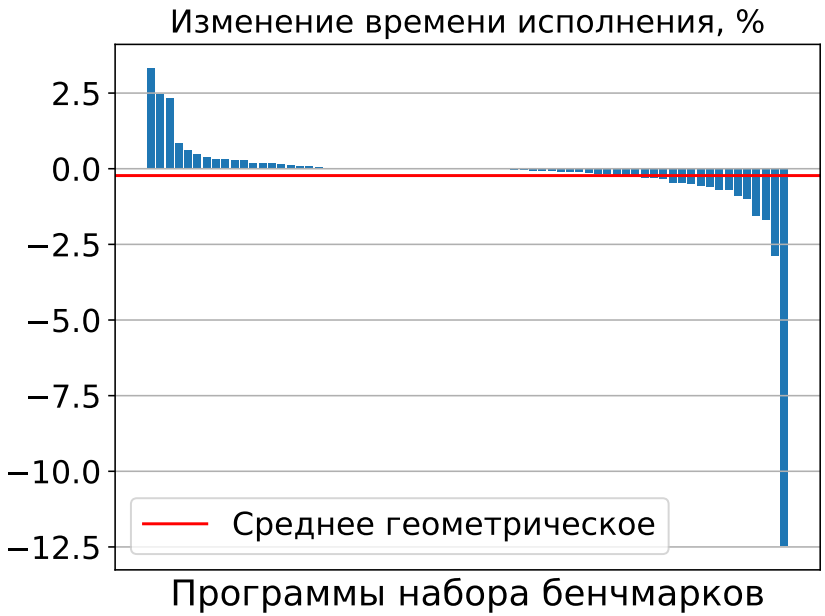

Заключение

- Показана необходимость улучшения алгоритма расположения инвариантов цикла в компиляторной инфраструктуре LLVM.
- Проведен общий анализ алгоритма, и анализ его применения к функции `S_regmatch`.
- Разработаны улучшения алгоритма пропагации инвариантов в тело цикла.
- Для улучшенного алгоритма, была доказана оптимальность получаемого расположения инвариантов.
- Алгоритм был реализован в компиляторной инфраструктуре LLVM.
- Анализ производительности:
  - Значительное увеличение для некоторых приложений
  - Прирост производительности в среднем.
- Изменения включены во внутреннюю поставку компилятора компании Синтакор.

Спасибо за внимание!